

BIOSEÑALES: PROYECTO 2. Análisis de señales ECG y detección de arritmias - análisis espectral

Omar Santiago Acevedo, Andrés Felipe Agudelo, Manuela Santamaría Valencia

Resumen:

El presente proyecto tuvo como objetivo el análisis espectral de señales electrocardiográficas (ECG) para la detección y caracterización de arritmias cardíacas, particularmente la fibrilación auricular (AFIB) y la bradicardia sinusal (SB). A partir de una base de datos clínica, se seleccionaron registros balanceados por clase y edad, sobre los cuales se aplicaron técnicas de procesamiento de señal y extracción de características en el dominio de la frecuencia. Se implementaron tres transformadas: la Transformada Discreta de Fourier (DFT), la Transformada Discreta del Coseno (DCT) y los Coeficientes Cepstrales en Frecuencias de Mel (MFCC), con el fin de evaluar su capacidad discriminativa entre ritmos normales y patológicos.

Las señales fueron analizadas mediante algoritmos automáticos de detección de picos R, y se extrajeron métricas espectrales como frecuencia dominante, energía total y banda útil. Asimismo, se calcularon 13 coeficientes principales por cada método de transformación para comparar perfiles espectrales. La comparación estadística entre grupos se realizó usando la prueba de Mann-Whitney U, mostrando que los coeficientes MFCC ofrecieron mayor poder discriminativo (8 de 13 coeficientes con significancia estadística), seguidos por DFT y DCT. Estos hallazgos se visualizaron mediante diagramas de caja y un mapa de calor de valores p. Los resultados confirman que las transformadas espectrales, en especial los MFCC, son herramientas eficaces para representar la morfología compleja del ECG y para diferenciar entre tipos de arritmia. El estudio resalta la utilidad de enfoques espectrales y no paramétricos en el desarrollo de modelos de detección automática de ritmos cardíacos anómalos, contribuyendo así a la mejora de herramientas diagnósticas en cardiología clínica.

I. INTRODUCCIÓN

El electrocardiograma (ECG) es una técnica no invasiva fundamental en la medicina cardiovascular, utilizada para registrar la actividad eléctrica del corazón a través de electrodos colocados sobre la piel. Su funcionamiento se basa en la detección de diferencias de potencial generadas por la despolarización y repolarización del músculo cardíaco. Estas señales eléctricas se traducen en trazos visuales que reflejan los distintos eventos del ciclo cardíaco, como la onda P, el complejo QRS y la onda T. Gracias a su alta resolución temporal, el ECG permite identificar variaciones en el ritmo, la conducción y la morfología de la señal, lo que lo convierte en una herramienta esencial para la detección de arritmias cardíacas [1].

Entre las arritmias más comunes y clínicamente relevantes se encuentran la fibrilación auricular (AFIB) y la bradicardia sinusal (SB). La fibrilación auricular se caracteriza por una actividad auricular rápida, desorganizada y caótica, que en el ECG se evidencia mediante la ausencia de ondas P definidas y la presencia de intervalos R-R irregulares. En cambio, la bradicardia sinusal corresponde a un ritmo sinusal regular, pero con una frecuencia cardíaca anormalmente baja (<60 lpm), lo cual se manifiesta en el ECG como una separación excesiva entre complejos QRS. A pesar de que estas arritmias presentan patrones característicos, su identificación puede ser problemática debido a la variabilidad entre pacientes, la presencia de ruido y artefactos en las señales, y la superposición de características con otros trastornos cardíacos[1].

El análisis computacional del ECG requiere el uso de herramientas que permitan transformar las señales desde el dominio temporal al dominio de la frecuencia, donde ciertos patrones espectrales pueden ser más evidentes. Una de las herramientas más utilizadas en este contexto es la Transformada Discreta de Fourier (DFT). La DFT permite descomponer una señal en una suma de senos y cosenos de distintas frecuencias, facilitando la identificación de componentes periódicos y su intensidad. Su utilidad ha sido ampliamente demostrada en el análisis espectral de señales fisiológicas, incluida la detección de irregularidades en los ritmos cardíacos [21][22].

Complementaria a la DFT, la Transformada Discreta del Coseno (DCT) se ha consolidado como una alternativa eficaz para el procesamiento de señales biomédicas. A diferencia de la DFT, la DCT utiliza únicamente cosenos, lo cual permite una mejor compresión de la energía en los primeros coeficientes, destacando patrones relevantes con menor redundancia. Esta propiedad la convierte en una herramienta eficiente para el análisis y clasificación de señales ECG, particularmente en el contexto de sistemas automáticos de detección de arritmias, donde se busca reducir la dimensionalidad de los datos sin perder información significativa [21].

Una técnica derivada del análisis espectral es la extracción de coeficientes cepstrales en las frecuencias de Mel (MFCC, por sus siglas en inglés). Aunque originalmente desarrollados para el reconocimiento de voz, los MFCC se han aplicado exitosamente al análisis de señales fisiológicas como el ECG. Al modelar la percepción humana del sonido,

los MFCC logran representar las características espectrales de una señal de forma compacta y discriminativa, lo cual ha demostrado ser útil para clasificar distintos tipos de ritmos cardíacos, incluyendo los normales y los patológicos como AFIB y SB [22].

La integración de estas herramientas es crucial para el desarrollo de sistemas robustos de detección automática de arritmias. Cada una aporta un enfoque complementario para resaltar características clave en la señal cardíaca, desde su estructura rítmica hasta su contenido espectral. En conjunto, permiten construir representaciones eficientes y diferenciables que favorecen la clasificación precisa de distintos trastornos del ritmo cardíaco, contribuyendo así a un diagnóstico temprano y oportuno.

II. METODOLOGÍA

Sección a

En esta sección se realizó una extensión y una serie de ajustes al desarrollado en el pasado proyecto, manteniendo la base metodológica en el procesamiento y análisis de señales electrocardiográficas (ECG). La principal modificación consiste en el enfoque exclusivo en dos grupos clínicos específicos: fibrilación auricular (AFIB) y ritmo sinusal bradicárdico (SB). Esto con el fin de poder realizar una comparación más focalizada y clínica entre ritmos cardíacos con implicaciones diagnósticas relevantes.

Nuestra primera idea de ajuste fue para el entrenamiento de algoritmos de aprendizaje automático aplicados al análisis de señales ECG, para esto es fundamental utilizar conjuntos de datos que sean tanto extensos como comparables. En este sentido, la comparabilidad se garantiza cuando los datos provienen de poblaciones relativamente homogéneas en cuanto a factores fisiológicos como la edad, dado que factores como la variabilidad de la frecuencia cardíaca (HRV) cambian significativamente a lo largo del ciclo vital. Por ejemplo, se ha demostrado que la HRV disminuye progresivamente con la edad, especialmente después de los 60 años, lo que podría introducir sesgos si se mezclan rangos etarios muy amplios en el entrenamiento de modelos de clasificación [1].

En nuestro análisis previo de la base de datos ChapmanECG, observamos que las clases de Bradicardia Sinusal (SB) y Ritmo Sinusal (SR) eran suficientemente representativas en cuanto a cantidad de registros, género y distribución etaria. Por ello, optamos por limitar la población seleccionada a pacientes entre 20 y 80 años, excluyendo aquellos por debajo de 20 años —donde es más frecuente la taquicardia sinusal fisiológica— y aquellos mayores de 80 años, cuyo envejecimiento cardíaco puede

afectar considerablemente la dinámica de la señal [1], [2]. Este análisis continúa cobrando sentido aun después de haber hecho el cambio de SR por AFIB, dado que los datos siguen siendo los mismos, sin embargo, nuevos factores importantes se deben considerar como por ejemplo la prevalencia de AFIB en personas mayores[3].

En el entrenamiento de algoritmos para detección de arritmias, es esencial incluir registros de Ritmo Sinusal (SR) como clase de referencia fisiológica. Esto se debe a que los modelos supervisados requieren ejemplos tanto positivos (con arritmias) como negativos (sin arritmias) para aprender a discriminar entre patrones normales y patológicos. El SR representa el ritmo cardíaco típico en reposo, caracterizado por una activación eléctrica regular originada en el nodo sinusal, y su inclusión permite al modelo identificar correctamente a pacientes sanos y evitar falsos positivos. Además, en tareas de clasificación multiclase, la presencia de SR como clase base mejora la capacidad discriminativa general del modelo y permite construir herramientas de diagnóstico más robustas y clínicamente útiles [1], [2].

La incorporación de Fibrilación Auricular (AFIB) al algoritmo de aprendizaje toma mucho sentido pues es una de las arritmias más prevalentes a nivel global, particularmente en adultos mayores[3]. Su incidencia aumenta exponencialmente con la edad, afectando aproximadamente al 10% de las personas mayores de 80 años, lo que la convierte en una prioridad diagnóstica en cardiología preventiva y de riesgo [3] [5]. Su morfología irregular —caracterizada por intervalos RR variables y la ausencia de ondas P— ofrece patrones distintivos que son fácilmente capturables por algoritmos de extracción de características en el dominio temporal y espectral [1][12]. La inclusión de AFIB en el conjunto de entrenamiento permite no solo mejorar la capacidad de discriminación del modelo, sino también su aplicabilidad clínica al contribuir en la detección temprana de esta arritmia, que se asocia a un mayor riesgo de accidente cerebrovascular y deterioro cognitivo si no se trata adecuadamente [3], [5].

Existe una coincidencia sustancial entre lo reportado en la literatura científica y lo observado en la base de datos ChapmanECG. En primer lugar, diversos estudios han señalado que el ritmo sinusal (SR) es el patrón electrocardiográfico más común en individuos sanos y sirve como base para la detección de arritmias cardíacas [4]. En concordancia, la base de datos utilizada muestra una amplia representación de esta clase, con aproximadamente 1.950 registros de SR. Asimismo, la bradicardia sinusal (SB) —caracterizada por una frecuencia cardíaca inferior a 60 latidos por minuto— es una condición frecuente en sujetos jóvenes, deportistas o durante el reposo, y su presencia ha sido documentada con alta prevalencia en registros ambulatorios [5]. En la base ChapmanECG, esta clase

representa el mayor número de muestras (cerca de 3.900), lo cual está en línea con esa descripción clínica.

Por otro lado, estudios epidemiológicos confirman que la fibrilación auricular (AF) y otras arritmias auriculares como el flutter auricular (AFIB) y la taquicardia auricular (AT) aumentan en frecuencia con la edad, especialmente a partir de los 65 años [3]. Esta tendencia también se evidenció en nuestro análisis de *Diagnostics.xlsx*, donde observamos que la proporción de pacientes con AF, AFIB o AT crece de forma notable en los grupos etarios más avanzados. Esta relación entre edad y arritmias auriculares respalda lo encontrado en literatura y sugiere que la base ChapmanECG tiene un diseño representativo de la distribución real de estas condiciones en la población clínica.

Además de los análisis realizados en este proyecto, se pueden implementar estudios complementarios que fortalezcan la capacidad diagnóstica y la generalización de modelos automáticos [13]. En primer lugar, se podría extender el análisis a una clasificación multiclase, incorporando ritmos adicionales como fibrilación auricular (AF), flutter auricular (AFIB), taquicardia auricular (AT), taquicardia ventricular (VT) y fibrilación ventricular (VF). Estas clases, aunque menos frecuentes que SB o SR, representan condiciones clínicamente críticas que pueden beneficiarse de una detección automatizada temprana [15]. Un enfoque basado en detección de arritmias mediante algoritmos de clasificación que analizan la forma de onda de los ECG, considerando tanto picos como morfología general, lo que podría ser replicado en esta base con técnicas actuales como redes neuronales convolucionales (CNN) [15].

Otro análisis propuesto sería el estudio de arritmias peligrosas y eventos agudos. Desarrollar un subconjunto de ECG específicamente para evaluar el desempeño de algoritmos en la identificación de ritmos con alto riesgo de muerte súbita, como fibrilación ventricular y taquicardia ventricular [14]. Si bien estos ritmos están menos representados en ChapmanECG, su inclusión estratégica permitiría entrenar modelos de alto impacto clínico en detección de emergencias cardíacas.

También se recomienda realizar un análisis espectral avanzado, usando transformadas como DFT, DCT o MFCC sobre los segmentos ECG, lo cual ha sido validado como útil en la literatura para mejorar la discriminación entre ritmos complejos y normales [4] [21].

Adicionalmente, sería valioso estudiar el efecto de variables demográficas como la edad y el sexo en la presentación y morfología de las distintas arritmias, para desarrollar modelos personalizados [1][2], pues estos demuestran que la variabilidad del ritmo cardíaco disminuye con la edad y difiere entre géneros, por lo que ajustar los modelos a estos

factores puede mejorar la precisión diagnóstica.

En procesamiento de señales electrocardiográficas (ECG), existen múltiples librerías de código abierto que permiten implementar análisis automáticos con distintos niveles de complejidad. Además de las herramientas empleadas en este proyecto —NeuroKit2 y hrvanalysis—, se han reportado otras librerías como BioSPPy, WFDB, py-ecg-detectors y HeartPy, las cuales presentan distintos enfoques metodológicos. BioSPPy, por ejemplo, está orientada a aplicaciones educativas y análisis básicos, ofreciendo detección de picos R mediante umbrales fijos y procesamiento simple de señales. Sin embargo, su rendimiento ante ruido y su incapacidad para detectar segmentos morfológicos más allá del QRS la limitan para estudios clínicos avanzados [17]. La librería WFDB, desarrollada por PhysioNet, es altamente útil para manipular bases de datos grandes como MIT-BIH o ChapmanECG, ya que permite leer archivos con anotaciones médicas y etiquetas expertas. No obstante, no realiza análisis fisiológico por sí misma, por lo que requiere que el usuario implemente su propio *pipeline* de procesamiento y detección de eventos [18].

Otra alternativa, py-ecg-detectors, proporciona acceso a múltiples algoritmos clásicos de detección de picos R (como Pan-Tompkins, Hamilton y Christov), lo cual es útil para estudios comparativos. Sin embargo, no permite extraer métricas de HRV ni realizar análisis morfológico, y su sensibilidad disminuye en presencia de artefactos o señales no ideales [19]. Por otro lado, HeartPy fue diseñada principalmente para analizar señales PPG (fotopletismográficas) en dispositivos portátiles, aunque también se ha aplicado a ECG con buenos resultados en condiciones ruidosas. Su enfoque está centrado en la extracción de HRV en tiempo real, pero no incluye la detección precisa de ondas P, T ni intervalos como el QT, lo que limita su aplicación en estudios de arritmia [20].

En contraste, NeuroKit2 ofrece un conjunto más completo y robusto de herramientas de procesamiento fisiológico: permite detectar múltiples eventos del ECG (ondas P, QRS, T), segmentar ciclos cardíacos, y extraer más de 20 métricas de HRV, incluyendo componentes lineales, no lineales y espectrales [21]. Su función `nk.ecg_process()` encapsula todo el *pipeline* desde el filtrado hasta la extracción de características, lo que la hace ideal para análisis automáticos en estudios de clasificación. Por su parte, hrvanalysis complementa este flujo con una implementación detallada de métricas específicas del dominio del tiempo, frecuencia y complejidad, validadas en entornos clínicos [22]. Por estas razones, la elección de NeuroKit2 y hrvanalysis en este proyecto fue adecuada, ya que permitió integrar un flujo robusto con capacidad de extraer información morfológica precisa y métricas de HRV

comparables con los estándares clínicos. Esta combinación es especialmente útil en el análisis de arritmias, donde los cambios en la morfología del ECG y en la variabilidad del ritmo son determinantes para la clasificación.

Se implementaron medidas no lineales como la entropía de Shannon y la entropía aproximada (ApEn), ambas calculadas directamente sobre los intervalos RR derivados de la detección de picos R. La entropía de Shannon permite cuantificar la impredecibilidad de la señal, mientras que ApEn evalúa la regularidad de los patrones en series temporales cortas, siendo altamente sensible a cambios abruptos en la dinámica cardíaca. Estas métricas han mostrado utilidad clínica en la identificación de ritmos caóticos como la fibrilación auricular, donde la variabilidad del latido es alta pero estructuralmente irregular [7], [8].

Adicionalmente, se calculó el índice SD1, derivado del diagrama de Poincaré, como medida de dispersión perpendicular al eje de identidad, lo que refleja la variabilidad a corto plazo del sistema nervioso autónomo, predominantemente bajo influencia parasimpática [9]. Esta métrica ha sido reconocida como un complemento robusto de RMSSD, especialmente en estudios de control vagal y respuesta rápida al estrés fisiológico [6].

Estas funciones fueron implementadas utilizando tanto rutinas personalizadas como capacidades integradas de las librerías mencionadas. En particular, *hrvanalysis*, la cual ofrece funciones automáticas para el cálculo de ApEn, SD1 y métricas espectrales como LF, HF y la razón LF/HF, permite un pipeline reproducible y clínicamente coherente. Por su parte, *NeuroKit2* permite una extracción precisa de eventos cardíacos mediante funciones como `nk.ecg_delineate()` y `nk.hrv()`, que no solo detectan los picos R, sino que también identifican con alta precisión las ondas P, T, y los intervalos PR y QT, lo cual puede ser aprovechado en análisis morfológicos más complejos en estudios futuros [19].

Desde una perspectiva metodológica, estas métricas adicionales no solo enriquecen el conjunto de características para clasificación, sino que también aportan una descripción más completa del comportamiento del sistema nervioso autónomo en diferentes condiciones de ritmo cardíaco. Su inclusión es especialmente relevante considerando que algunos ritmos, como la bradicardia sinusal, pueden no mostrar alteraciones marcadas en SDNN o LF/HF, pero sí presentar patrones distintos en complejidad y estructura temporal [19].

La comparación entre distintos ritmos cardíacos es crucial para identificar características fisiológicas que permitan discriminar entre arritmias. En esta etapa del proyecto, se modificó el enfoque original que contrastaba los grupos SB (Bradicardia Sinusal) y SR (Ritmo Sinusal), para centrarse

en la comparación entre AFIB (Fibrilación Auricular) y SB, considerando la alta prevalencia clínica y relevancia diagnóstica de AFIB en poblaciones adultas mayores [3].

Se analizaron tres características de la variabilidad de la frecuencia cardíaca (HRV): SDNN (Desviación estándar de los intervalos RR), RMSSD (Raíz cuadrada de la media de las diferencias sucesivas), y LF/HF Ratio (relación entre las bandas de baja y alta frecuencia). Estas se extrajeron mediante las funciones de la biblioteca *hrvanalysis*, con detección de picos R empleando *NeuroKit2*, validada como la opción más precisa en el Análisis II del proyecto [19], [20].

Los resultados se evaluaron con estadísticas descriptivas y pruebas de hipótesis no paramétricas (Mann-Whitney U), dada la no normalidad de los datos. Se observaron diferencias estadísticamente significativas entre los grupos AFIB y SB para SDNN y RMSSD, mientras que LF/HF Ratio mostró mayor dispersión y menor capacidad discriminativa, evidenciado por sus *p-values* elevados. Estas observaciones concuerdan con la literatura, donde RMSSD se reporta como uno de los índices más sensibles para diferenciar disfunciones autonómicas en arritmias como la fibrilación auricular [6].

Los boxplots generados para cada métrica permitieron visualizar la distribución entre grupos, donde SB presentó una variabilidad HRV notablemente mayor. Los gráficos de barras con errores estándar (media \pm DE) reforzaron la mayor dispersión en las muestras AFIB, lo cual podría reflejar una desregulación autonómica más pronunciada, como la reducción de HRV como marcador en pacientes con fibrilación auricular persistente [6].

Cabe destacar que la implementación de un cálculo manual (implementación paso a paso de la fórmula matemática de RMSSD directamente en el código) sobre una señal representativa confirmó la validez computacional del *pipeline* de procesamiento, asegurando la robustez del análisis realizado. Esta triangulación entre métodos de cálculo, visualización gráfica y contraste estadístico fortalece la evidencia de que RMSSD continúa siendo una de las características más discriminantes, seguida por SDNN, mientras que LF/HF Ratio requiere mayor precaución interpretativa por su susceptibilidad a la variabilidad y el artefacto respiratorio [6][10][20].

El análisis estadístico de las características de HRV se realizó con el fin de determinar la capacidad discriminativa de distintos parámetros no lineales y espectrales para distinguir entre ritmos sinusales (SB) y fibrilación auricular (AFIB). Las métricas evaluadas incluyeron: **SD1**, **SampEn**, **HF Power**, **lf/hf_ratio**, **SDNN** y **RMSSD**, ampliamente utilizadas en estudios de modulación autonómica [6] [7] [8].

Para cada característica se generaron tres tipos de representaciones:

Boxplots: permiten observar la dispersión, la mediana y la presencia de valores atípicos para cada grupo. Esta técnica es útil para detectar diferencias de distribución entre clases sin asumir normalidad [6].

Violin plots + swarmplots: combinan la forma de la distribución (violin) y la visualización de cada punto individual (swarm), lo que brinda un entendimiento profundo de la densidad de los datos y la agrupación de valores. Esta visualización es especialmente útil cuando los valores de AFIB presentan asimetría o distribución sesgada.

Gráfico de barras con media \pm desviación estándar: facilita la comparación de la tendencia central y la variabilidad entre grupos. Fue utilizado para representar de forma sintética la diferencia promedio entre AFIB y SB.

Se utilizó la prueba no paramétrica **Mann–Whitney U** para evaluar si existían diferencias estadísticamente significativas entre los grupos AFIB y SB en cada característica analizada. Esta elección se justificó por la naturaleza no normal de varias de las variables (confirmada mediante gráficos Q–Q). La prueba se aplicó bajo la hipótesis nula $H_0: \text{MedianaAFIB} = \text{MedianaSB}$ con un nivel de significancia $\alpha = 0.05$.

Para una mejor visualización de los resultados, los valores p obtenidos fueron transformados como $-\log_{10}(p)$ y graficados con una línea de referencia en $-\log_{10}(0.05)$, como se muestra en la Figura correspondiente. Esta transformación permite destacar de forma más clara las características más discriminativas, como SD1, SDNN y RMSSD, que superaron el umbral de significancia

Con el fin de evaluar la normalidad de las características, se generaron gráficos Q–Q (Quantile-Quantile) por clase. Esta técnica compara la distribución empírica con una distribución normal teórica. En características como HF Power y SD1, se observaron desviaciones notables respecto a la línea de referencia, especialmente en el grupo AFIB, lo cual justifica la elección de métodos no paramétricos para el análisis estadístico [6].

Finalmente, se construyó un mapa de calor de correlación de Pearson entre las distintas características de HRV. Se observaron correlaciones altas entre SDNN, RMSSD, y SD1, lo cual es consistente con estudios previos que reportan alta colinealidad entre estas métricas lineales en condiciones fisiológicas [8][9]. Por otro lado, SampEn mostró correlaciones negativas con estas medidas, lo que refuerza su valor como métrica complementaria no lineal.

Sección b

Con el fin de comparar las características espectrales de señales de electrocardiograma (ECG) entre dos tipos de ritmos, bradicardia sinusal (SB) y fibrilación auricular (AFIB), se realizó un procesamiento sobre un subconjunto representativo de registros. La base de datos original incluía múltiples clases de arritmias, de las cuales se extrajeron 40 señales (20 correspondientes a AFIB y 20 a SB) mediante muestreo aleatorio estratificado, garantizando equilibrio entre clases y reproducibilidad mediante el uso de una semilla fija. La información del subconjunto seleccionado se consolidó en un archivo auxiliar para asegurar la trazabilidad.

Cada archivo de señal fue cargado desde la carpeta *ECGDataDenoised*, accediendo específicamente a la segunda columna de los archivos *.csv*, que contiene la señal ECG preprocesada para la eliminación de artefactos. Todas las señales presentaban una frecuencia de muestreo de 500 Hz. El prefiltrado aplicado permitió preservar el contenido espectral fisiológicamente relevante, eliminando el ruido de alta frecuencia típicamente asociado a interferencias musculares o eléctricas.

Las señales fueron procesadas mediante dos algoritmos de detección de picos R: uno basado en la biblioteca *NeuroKit2*, que implementa una cadena de filtrado adaptativo y detección automática de complejos QRS, y otro basado en el algoritmo clásico de Pan-Tompkins, implementado a través del paquete *ecgdetectors*. Ambos enfoques se aplicaron de forma paralela con el fin de evaluar la consistencia en la detección, y los picos identificados fueron graficados sobre la señal original para facilitar su validación visual.

El análisis de las características espectrales se llevó a cabo mediante la Transformada Discreta de Fourier (DFT), aplicada sobre la señal ECG ya filtrada. Para ello, se utilizó la implementación *np.fft.rfft* de NumPy, que retorna exclusivamente las componentes de frecuencia positiva. A partir de la transformada se calculó el espectro de potencia, definido como el cuadrado del módulo de los coeficientes complejos obtenidos. De este espectro se extrajeron tres características principales: la frecuencia dominante, definida como la frecuencia con máxima potencia; la energía espectral total, obtenida como la suma de todas las potencias en el dominio de la frecuencia; y la banda útil, que comprende el rango de frecuencias cuya potencia supera el 5% del valor máximo del espectro, permitiendo identificar el rango espectral fisiológicamente activo en cada señal.

Cada señal fue acompañada de una doble representación gráfica: por un lado, la señal filtrada en el dominio del tiempo con los picos detectados superpuestos, y por otro, el espectro de potencia que evidencia el contenido en

frecuencia. Los resultados extraídos (frecuencia dominante, energía total, número de picos detectados por ambos algoritmos y el ritmo cardíaco estimado en BPM) fueron almacenados en un archivo .xlsx para su posterior análisis estadístico y comparación entre los grupos AFIB y SB.

- implementación de la DFT

La DFT transforma una señal discreta $x[n]$ del dominio temporal al dominio de la frecuencia, permitiendo observar qué frecuencias componen la señal y con qué potencia. Su formulación matemática es:

$$X(k) = \sum_{n=0}^{N-1} x(n)e^{-j2\pi kn/N}$$

donde:

x[n]: señal ECG de entrada.

N: número total de muestras.

X[k]: componente espectral en la frecuencia discreta

j: unidad imaginaria.

En el código se utilizó, la función `np.fft.rfft()` que es la Transformada Rápida de Fourier (FFT) de la biblioteca NumPy la cual permitió obtener directamente el espectro de frecuencias positivas, dado que las señales ECG analizadas son reales. La equivalencia entre DFT y FFT se mantiene en los resultados la FFT se usa como optimización computacional de la DFT. La FFT permite obtener los coeficientes de frecuencia de forma eficiente con complejidad $O(N \log N)$, lo cual es crucial para el análisis de grandes volúmenes de datos biomédicos además permite cuantificar las variaciones en señales normales, siendo especialmente útil para distinguir entre ritmos regulares y desorganizados como la fibrilación auricular (AFIB) [12][21].

A partir del espectro de potencia $|X[k]|^2$, se calcularon las siguientes métricas:

1) Frecuencia dominante f_{dom} : componente con máxima potencia.

2) Energía total $E = \sum |X[k]|^2$: representa la potencia acumulada del ECG.

3) Banda útil: rango de frecuencias que contienen al menos el 5% de la energía máxima.

4) Centroide espectral y curtosis espectral pueden incorporarse para análisis más avanzados.

Este enfoque es coherente con la literatura, donde se destaca que las señales ECG, aunque no perfectamente periódicas, exhiben patrones de frecuencia que pueden capturar diferencias sutiles entre ritmos cardíacos normales y anómalos [12][21].

La elección de técnicas de análisis espectral se fundamenta tanto en la fisiología cardíaca como en consideraciones computacionales. La morfología ECG contiene componentes de baja frecuencia asociadas al ritmo cardíaco y componentes más altas que representan la despolarización rápida del ventrículo (complejo QRS)[1]. Además, se ha demostrado que el uso localizado de la DFT permite identificar patrones discriminatorios en regiones específicas del ECG, lo cual refuerza la utilidad de esta transformada para diagnóstico automatizado[21].

- Implementación de la DCT

Tras el análisis espectral mediante la Transformada Discreta de Fourier (FFT), se implementó un enfoque complementario para la extracción de características basado en la Transformada Discreta del Coseno (DCT). A diferencia de la FFT, que representa la señal como una combinación de funciones seno y coseno en el dominio complejo, la DCT opera únicamente sobre funciones coseno reales y ofrece una representación más compacta y eficiente para señales periódicas o cuasi estacionarias, como las señales ECG. La DCT ha sido ampliamente utilizada en compresión de datos y procesamiento biomédico, debido a su capacidad para concentrar la energía de la señal en pocos coeficientes [1].

Matemáticamente, la DCT tipo II, que es la forma más utilizada en procesamiento de señales, está definida para una señal discreta $x[n]$, $n = 0, \dots, N - 1$, como:

$$X_k = \alpha(k) \sum_{n=0}^{N-1} x[n] \cos\left[\frac{\pi}{N}\left(n + \frac{1}{2}\right)k\right], k = 0, \dots, N - 1$$

donde:

$$\alpha(k) = \sqrt{\frac{1}{N}}, k = 0 \quad \alpha(k) = \sqrt{\frac{1}{N}}, k \neq 0$$

La misma cohorte de señales utilizada en el análisis por FFT fue reaprovechada para esta etapa. Cada una de las 40

señales fue filtrada nuevamente con un filtro pasabanda (0.5–40 Hz) con el objetivo de mantener coherencia metodológica entre ambos enfoques. Posteriormente, se aplicó la DCT tipo II (la forma más comúnmente empleada en análisis de señales fisiológicas) utilizando la implementación `scipy.fftpack.dct` con normalización ortonormal (`norm='ortho'`), lo que garantiza que los coeficientes resultantes puedan ser comparables en escala.

De la salida de la transformada se seleccionaron los 20 primeros coeficientes DCT para cada señal, los cuales capturan los patrones más relevantes de baja y media frecuencia. Esta selección se basó en la observación empírica de que la mayor parte de la energía de la señal se encuentra contenida en los primeros componentes, mientras que los coeficientes de orden superior suelen corresponder a ruido o información redundante [22]. Estos coeficientes permiten captar patrones morfológicos relevantes para la diferenciación entre ritmos AFIB y SB.

La DCT se aplicó directamente sobre la señal filtrada completa, ya que el objetivo era obtener una caracterización global de la forma de onda, y no su variabilidad temporal. Los coeficientes obtenidos fueron graficados individualmente mediante diagramas de tallo para facilitar su inspección visual y comparar las distribuciones entre señales de tipo AFIB y SB.

Además, los coeficientes DCT fueron almacenados junto con los resultados del análisis de picos (NeuroKit2 y Pan-Tompkins) en una hoja de cálculo.

- implementación de la MFCC

Tras aplicar análisis espectrales globales mediante DFT y DCT, se incorporó un enfoque más avanzado de extracción de características: los coeficientes cepstrales en las frecuencias de Mel (Mel-Frequency Cepstral Coefficients). Originalmente desarrollados para aplicaciones de reconocimiento de voz, los MFCC se han adaptado exitosamente a señales biomédicas, incluido el ECG, debido a su capacidad de capturar información morfológica localizada y robusta al ruido [12][13]. Construyendo el algoritmo mediante rutinas básicas en Python, sin uso de bibliotecas especializadas como `librosa`. Esta biblioteca abstrae gran parte del proceso de cálculo de MFCC en una única función desde el enmarcado de la señal hasta la aplicación de la DCT sobre el espectro Mel. Al evitar estas abstracciones se garantiza un mayor control sobre parámetros específicos del dominio biomédico, como el rango de frecuencias cardíacas (0.5–40 Hz), que difiere del rango típico en procesamiento de voz [12].

Los MFCC se obtienen aplicando una secuencia de transformaciones sobre la señal:

1. **Enmarcado (Framing):** se dividió cada señal en ventanas solapadas de 300 ms con pasos de 150 ms, coherente con la duración típica de un latido cardíaco.
2. **Ventaneo:** cada segmento fue multiplicado por una ventana de Hamming para minimizar el efecto de discontinuidades en los bordes.
3. **Transformada rápida de Fourier (FFT):** se aplicó a cada segmento para obtener el espectro de potencia.
4. **Bancos de filtros de Mel:** el espectro fue proyectado sobre un conjunto de 26 filtros triangularmente distribuidos en escala Mel, entre 0.5 Hz y 40 Hz, abarcando el rango fisiológicamente relevante del ECG.
5. **Logaritmo del espectro de Mel:** para simular la percepción logarítmica de energía.
6. **Transformada Discreta del Coseno (DCT):** aplicada sobre el log-energía de Mel para obtener los coeficientes cepstrales.

El cálculo matemático de los coeficientes MFCC puede resumirse como

$$MFCC_k = \sum_{m=1}^M \log(E_m) \cdot \cos\left[\frac{\pi k}{M} \left(m - \frac{1}{2}\right)\right], k = 1, \dots, K$$

donde:

- **Em** es la energía resultante del filtro Mel número *m*.
- **M** es el número total de filtros (26).
- **K** es el número de coeficientes seleccionados (los primeros 13).

Para cada señal, se promediaron los coeficientes obtenidos por ventana, generando un vector MFCC representativo de 13 dimensiones por señal. Esta dimensionalidad fue seleccionada por ser comúnmente utilizada en aplicaciones biomédicas y por capturar adecuadamente las características dominantes [12][13][21].

A diferencia de la DCT, que captura componentes de frecuencia global, los MFCC extraen representaciones morfológicas locales, más sensibles a cambios sutiles entre tipos de arritmia. Esta propiedad los hace especialmente

útiles para aplicaciones de clasificación automática [12][21]. En esta implementación se observó que los coeficientes MFCC eran capaces de reflejar diferencias cuantitativas entre señales AFIB y SB, particularmente en los coeficientes de orden bajo y medio.

Cada conjunto de coeficientes fue almacenado en un archivo Excel junto con el nombre del archivo original y la clase de arritmia correspondiente. Para su análisis visual, se generaron gráficos discretos tipo diagrama de tallo, uno por señal, y se compararon los perfiles espectrales entre clases.

Con el objetivo de evaluar la capacidad discriminativa de distintas representaciones espectrales de la señal ECG, se aplicó una comparación estadística entre los grupos AFIB y SB sobre las características extraídas por tres transformadas: MFCC, DFT y DCT.

Las Mel-Frequency Cepstral Coefficients (MFCC), comúnmente utilizadas en procesamiento de voz, se han explorado recientemente en contextos biomédicos debido a su capacidad para representar componentes no lineales y de bajo nivel energético en señales fisiológicas [12]. Por otro lado, la transformada de Fourier (DFT) y la transformada discreta del coseno (DCT) son ampliamente utilizadas para capturar contenido frecuencial, incluyendo transformaciones aplicadas sobre ventanas móviles del ECG o sobre series de intervalos RR [13][21] [22].

Se extrajeron 13 coeficientes principales de cada transformada (denotados como F1 a F13) por cada segmento de señal, y se agruparon según el tipo de arritmia (AFIB o SB). Para cada característica se aplicó la prueba de Mann-Whitney U, una prueba no paramétrica adecuada para comparar dos grupos independientes con distribuciones no necesariamente normales [6].

Los valores p obtenidos fueron organizados en una matriz de calor (ver Figura X), donde se evidencia que el método MFCC presentó la mayor cantidad de características significativamente distintas entre los grupos (8 de 13), seguido de DFT y DCT, ambos con 2 características significativas. En particular, la característica F11 fue significativa de forma consistente en los tres métodos, lo cual sugiere su utilidad potencial como descriptor robusto para discriminación de ritmos cardíacos.

Estos resultados apoyan el uso de representaciones espectrales cepstrales como herramienta complementaria para el análisis de señales ECG, especialmente en tareas de clasificación o diagnóstico automatizado de arritmias [12], [13].

Para representar las señales ECG en un espacio espectral no lineal y de baja dimensión, se implementó el cálculo de

coeficientes cepstrales en escala Mel (MFCC). El proceso de extracción de MFCC aplicado en este estudio consta de las siguientes etapas:

Segmentación temporal (framing): la señal ECG se dividió en ventanas de 300 ms con un solapamiento del 50 %, equivalente a un paso de 150 ms. Este enfoque permite preservar la dinámica temporal y obtener representaciones locales de la señal. A cada ventana se le aplicó una ventana de Hamming para reducir las discontinuidades en los bordes y minimizar el efecto de fugas espectrales (Gibbs) al aplicar la FFT.

$$frame_length = \frac{fs \times frame_length_ms}{1000}$$

- Transformada rápida de Fourier (FFT) y espectro de potencia: se calculó la FFT de cada ventana y se extrajo el módulo de sus componentes. Posteriormente, se obtuvo el espectro de potencia para cada frame normalizando por el número de puntos, lo que proporciona una representación en el dominio de la frecuencia de la energía contenida en la señal.

$$P[k] = \frac{1}{N} |FFT_k|^2$$

- Banco de filtros en escala Mel: se diseñó un conjunto de 26 filtros triangulares distribuidos de forma equiespaciada en la escala perceptual Mel, entre 0.5 Hz y 40 Hz, frecuencia en la que se concentra la mayor parte del contenido fisiológico relevante del ECG [12], [13]. Esta escala simula la sensibilidad del oído humano, pero ha demostrado ser útil también para comprimir la información de señales biológicas en bandas no lineales.

$$mel = 2595 \cdot \log_{10}(1 + \frac{f}{700})$$

$$f = 700 \cdot (10^{mel/2595} - 1)$$

- Cálculo de energía en bandas Mel y Escalado logarítmico: cada espectro de potencia fue proyectado sobre el banco de filtros, lo cual da como resultado la energía en cada banda Mel. Para simular la percepción logarítmica del oído (y estabilizar la varianza), se aplicó el logaritmo natural a las energías en banda.

$$Emel[i] = \sum_k P[k] \cdot Hi[k]$$

$$\log(Emel + \epsilon)$$

$$MFCCj = \sum_i \log(Emel[i]) \cdot \cos\left[\frac{\pi j(i+0.5)}{n}\right]$$

- Transformada Discreta del Coseno (DCT): a cada vector log-Mel se le aplicó la DCT de tipo II, la cual reduce la redundancia y produce una representación más compacta y correlacionada. Se conservaron únicamente los primeros 13 coeficientes, que representan la envolvente espectral de forma eficiente.
- Promedio temporal: finalmente, se promediaron los MFCCs obtenidos a lo largo de todas las ventanas para cada señal ECG, obteniendo así un vector de características de 13 dimensiones por muestra..

III. RESULTADOS

El análisis espectral mediante la Transformada Discreta de Fourier (FFT) se aplicó a un conjunto total de 40 señales ECG, con 20 pertenecientes al grupo de fibrilación auricular (AFIB) y 20 al grupo de bradicardia sinusal (SB). A continuación, se presentan seis señales representativas tres de cada grupo (para ilustrar las diferencias espectrales encontradas).

Las señales del grupo AFIB se caracterizan por frecuencias dominantes que varían entre 0 Hz y 6.50 Hz. Por ejemplo, la señal MUSE_20180113_135820_25000 (figura 1) mostró una frecuencia dominante máxima de 6.50 Hz, acompañada de una energía total de 6.32×10^{10} unidades y una banda útil que se extendió entre 0.00 – 32.41 Hz, reflejando un ritmo cardíaco rápido y una morfología compleja con componentes de frecuencia intermedia y alta. La señal MUSE_20180114_071109_97000 (figura 2) presentó una frecuencia dominante de 3.30 Hz con una energía de 2.19×10^{10} y una banda útil que llegó hasta los 20.20 Hz, indicativa de una señal con variabilidad fisiológica significativa. Por último, la señal MUSE_20180113_125914_52000 (figura 3) tuvo una frecuencia dominante intermedia de 1.90 Hz, con energía total y banda útil moderadas, de 1.15×10^{10} y hasta 14.30 Hz, respectivamente.

En contraste, las señales del grupo SB exhibieron frecuencias dominantes más bajas, entre 3.00 Hz y 3.90 Hz, y energías totales en promedio menores. Por ejemplo, la señal MUSE_20180116_124254_77000 (figura 4) mostró una frecuencia dominante de 3.80 Hz, con energía total de 7.74×10^9 y banda útil estrecha hasta 8.60 Hz, caracterizando un ritmo más lento y estable. La señal MUSE_20180112_123219_61000 (figura 5) presentó una frecuencia dominante cercana (3.90 Hz) pero con mayor

energía (2.14×10^{10}) y banda útil extendida hasta los 21.70 Hz, lo que indica cierta variabilidad morfológica incluso dentro del grupo SB. La señal MUSE_20180118_123232_60000 (figura 6) tuvo la frecuencia dominante más baja de 3.00 Hz y una banda útil que abarcó hasta 18.10 Hz, con energía total intermedia de 1.32×10^{10} .




Figura 1 Espectro de potencia y señal con ecgdetectors y neurokit2 de la MUSE_20180113_135820_25000




Figura 2 Espectro de potencia y señal con ecgdetectors y neurokit2 de la MUSE_20180114_071109_97000




Figura 3 Espectro de potencia y señal con ecgdetector y neurokit2 de la MUSE_20180113_125914_52000




Figura 6 Espectro de potencia y señal con ecgdetector y neurokit2 de la MUSE_20180118_123232_60000




Figura 4 Espectro de potencia y señal con ecgdetector y neurokit2 de la MUSE_20180114_114850_77000




Figura 5 Espectro de potencia y señal con ecgdetector y neurokit2 de la MUSE_20180112_123219_61000

Estos resultados demuestran que las señales de tipo SB tienden a concentrar su energía en bandas de frecuencia más estrechas, mientras que las señales AFIB exhiben un espectro más amplio y energético, reflejando una mayor complejidad morfológica. Las diferencias observadas en la distribución de potencia espectral constituyen una base sólida para su utilización como características discriminativas en modelos de clasificación automática de ritmos cardíacos.

El análisis espectral mediante la Transformada Discreta del Coseno (DCT) se aplicó a un conjunto total de 40 señales ECG, con 20 pertenecientes al grupo de fibrilación auricular (AFIB) y 20 al grupo de bradicardia sinusal (SB). A continuación, se presentan siete señales representativas, tres de AFIB y cuatro de SB (para ilustrar las diferencias espectrales encontradas).

La señal MUSE_20180113_135820_25000, apreciable en la figura 7, se caracteriza por un patrón regular y simétrico, con coeficientes de magnitud moderada: El primer coeficiente (DC) es positivo y de baja magnitud, lo que sugiere una componente de bajo nivel continuo. La distribución de los siguientes coeficientes muestra una variación suave entre valores positivos y negativos con picos pequeños entre los índices 6 y 10. Este perfil sugiere que la señal original tiene una estructura algo periódica pero sin componentes abruptas, típico de una fibrilación auricular de baja intensidad espectral y morfología no agresiva. La energía se concentra en las frecuencias intermedias (coef. 5–12), lo que indica oscilaciones no tan rápidas pero sí irregulares.




Figura 7 gráfica de los 20 primeros coeficientes de la transformada del coseno

Ahora, para la señal MUSE_20180118_123219_61000, apreciable en la figura 8, indica un caso que muestra un comportamiento más agresivo en magnitud, con variabilidad notable: El primer coeficiente presenta una magnitud considerable, indicando un fuerte componente de nivel basal con un valor que supera los 2000 en magnitud. Hay picos intensos en los coeficientes 3, 5 y 10, tanto positivos como negativos, lo que indica transiciones bruscas en la señal original (frecuencias intermedias dominantes). El patrón sugiere la presencia de componentes armónicos significativos, posiblemente ligados a actividad eléctrica desorganizada típica de una fibrilación auricular más avanzada o sostenida. Además, se aprecia una asimetría entre coeficientes pares e impares, indicando una morfología compleja y poco repetitiva.




Figura 8 gráfica de los 20 primeros coeficientes de la transformada del coseno

La señal MUSE_20180113_182033_51000, apreciable en la figura 9, se destaca por tener los coeficientes de mayor magnitud en todo el conjunto: Coeficientes como el 2, 4, 6 y 10 tienen magnitudes que alcanzan y superan los 2000, e inclusive el primer coeficiente supera los 4000, (positivos y negativos), lo que indica la existencia de componentes espectrales fuertemente dominantes. Este tipo de distribución es indicativo de una señal altamente inestable, donde la actividad eléctrica presenta fluctuaciones abruptas y caóticas. La señal base parece tener un contenido de alta energía en varias frecuencias, confirmando la presencia de fibrilación auricular severa con variabilidad extrema del ritmo.




Figura 9 gráfica de los 20 primeros coeficientes de la transformada del coseno

Las gráficas DCT para pacientes con AFIB reflejan características como: Alta variabilidad entre coeficientes, en magnitud y signo. Dominancia de componentes intermedias y altas, lo que es coherente con la irregularidad y complejidad morfológica del ECG en AFIB. Las señales MUSE_20180113_135820_25000, MUSE_20180118_123219_61000, y MUSE_20180113_182033_51000 representan bien tres niveles de severidad: de bajo, medio y alto contenido espectral respectivamente.

Para abordar las señales de SB se tienen:

La señal MUSE_20180113_074520_38000, apreciable en la figura 10, presenta un patrón altamente regular y simétrico. El primer coeficiente (DC) es marcadamente positivo y de gran magnitud, lo que indica una componente continua dominante. Los coeficientes restantes muestran una rápida caída de magnitud con oscilaciones suaves en torno a cero, sin picos abruptos. Este perfil sugiere que la señal original es de baja frecuencia y periódica, consistente con una bradicardia sinusal típica, donde el ritmo cardíaco se mantiene ordenado aunque lento, denotando una estructura rítmica y sin complejidad espectral.




Figura 10 gráfica de los 20 primeros coeficientes de la transformada del coseno

La señal MUSE_20180114_121621_22000, mostrada en la figura 11, refleja una estructura armónica estable. El coeficiente DC es positivo y de alta magnitud, seguido por una serie de coeficientes de baja a moderada amplitud que alternan suavemente entre signos positivos y negativos. Se observan picos moderados entre los coeficientes 6 y 10, sin que se genere una dispersión caótica. Esta disposición sugiere una señal de comportamiento periódico y estable, con oscilaciones suaves, típica de una bradicardia sinusal sin alteraciones de ritmo.




Figura 11 gráfica de los 20 primeros coeficientes de la transformada del coseno

La señal MUSE_20180118_181829_13000, visible en la figura 12, se caracteriza por un patrón simétrico con coeficientes de magnitud moderada y dispersión relativamente uniforme. El primer coeficiente (DC) es positivo y elevado, mientras que el resto presenta variaciones suaves con picos discretos a lo largo del espectro. Hay presencia de coeficientes intermedios (índices 5 a 12) con magnitudes algo mayores, lo cual podría corresponder a oscilaciones leves dentro de un marco rítmico conservado. Este tipo de perfil es compatible con señales de bradicardia sinusal con una leve modulación, pero sin pérdida de regularidad ni irrupciones abruptas.




Figura 12 gráfica de los 20 primeros coeficientes de la transformada del coseno

La señal MUSE_20180112_135452_58000, representada en la figura 13, exhibe un coeficiente DC positivo y dominante, seguido por una serie de coeficientes de magnitud baja y relativamente estables. A partir del coeficiente 5, las magnitudes oscilan levemente entre valores positivos y negativos, sin superar valores significativos. No se aprecian picos pronunciados ni dispersión espectral relevante. Esta configuración sugiere una señal con un ritmo cardíaco muy regular, sin actividad de alta frecuencia ni ruido abrupto, como se espera en registros típicos de bradicardia sinusal. La energía se encuentra claramente concentrada en los primeros coeficientes (1–4), lo cual enfatiza la baja complejidad morfológica de la señal.




Figura 13 gráfica de los 20 primeros coeficientes de la transformada del coseno

Las gráficas DCT para pacientes con bradicardia sinusal (SB) muestran un comportamiento espectral marcado por la baja variabilidad entre coeficientes, tanto en magnitud como en signo. Se observa una dominancia clara del primer coeficiente (DC), que representa una componente continua fuerte, y una rápida atenuación en los coeficientes subsiguientes. Esta distribución es coherente con la naturaleza rítmica, periódica y de baja frecuencia típica del ECG en SB, sin actividad caótica ni componentes de alta frecuencia.

Las señales MUSE_20180114_121621_22000, MUSE_20180118_181829_13000 y MUSE_20180112_135452_58000 ilustran adecuadamente tres grados de complejidad espectral creciente, representando perfiles de baja, media y moderada dispersión energética respectivamente. Aun así, todas conservan un patrón estructurado, sin presencia de irregularidades abruptas, lo cual es característico de un ritmo sinusal estable aunque lento.

MFCC

MUSE_20180114_135033_25000 - AFIB

Esta señal presenta una de las magnitudes más altas en el segundo coeficiente (alrededor de 32.5), lo que sugiere una fuerte concentración de energía en las bajas frecuencias o en la primera banda de frecuencia mel significativa. A partir de ahí, las magnitudes disminuyen progresivamente, aunque con un repunte en el quinto coeficiente (alrededor de 10) y el décimo (alrededor de 7.5). El último coeficiente (13) muestra una magnitud muy alta, lo que podría indicar una característica distintiva o un posible artefacto.

La mayoría de los coeficientes son positivos, lo que es común. Se observa un coeficiente negativo en el sexto y en el undécimo (aproximadamente -2.5 y -1 respectivamente). Estos valores negativos sugieren un valle en el espectro en esas bandas de frecuencia.

La secuencia de coeficientes muestra una tendencia general de disminución de magnitud, pero con notables irregularidades o picos en los coeficientes 5 y 10, lo que indica una morfología espectral compleja y no monótona. La gran magnitud del segundo coeficiente y la irregularidad general podrían reflejar el comportamiento errático de las contracciones auriculares en la fibrilación auricular.




Figura 14 gráfica de los 13 índices utilizando MFCC

MUSE_20180113_135820_25000 - AFIB

Similar a la señal anterior, el segundo coeficiente exhibe la magnitud más alta (alrededor de 32.5). Las magnitudes de los coeficientes subsiguientes descienden, con un notable repunte en el quinto (alrededor de 10) y el décimo (alrededor de 7.5). El coeficiente 13 es nuevamente muy alto. Predominan los coeficientes positivos. Se observan valores negativos en el sexto coeficiente (alrededor de -1.0) y en el undécimo (alrededor de -1.0). La progresión de las magnitudes es relativamente irregular. Aunque hay una tendencia general a la baja, los picos en los coeficientes 5 y 10, y el valor negativo en el 6 y 11, rompen la regularidad. Esto podría indicar que la señal cardíaca de este paciente presenta variaciones significativas en la distribución de energía a través de diferentes bandas de frecuencia, lo que es consistente con la naturaleza caótica de la fibrilación auricular.




Figura 15 gráfica de los 13 índices utilizando MFCC

MUSE_20180114_071048_14000 - AFIB

El segundo coeficiente es el más prominente, con una magnitud que se acerca a 32.5. Los coeficientes subsiguientes muestran una disminución general en magnitud, aunque con picos notados en el quinto (alrededor de 7.5) y el décimo (alrededor de 5). El coeficiente 13 tiene una magnitud muy alta. Todos los coeficientes mostrados hasta el 12 son positivos. El coeficiente 13, aunque muy alto, parece ser positivo. La serie de coeficientes presenta una tendencia general a la baja, pero con "ondas" o variaciones en la magnitud (picos en 5 y 10), lo que la hace irregular. La ausencia de coeficientes negativos en este rango (1-12) es una peculiaridad en comparación con las otras señales analizadas, lo que podría sugerir una estructura

espectral donde no hay valles profundos en las bandas de frecuencia correspondientes a esos coeficientes. Sin embargo, esto no implica una señal "normal" ya que la fibrilación auricular es inherentemente irregular.




Figura 16 gráfica de los 13 índices utilizando MFCC

Las gráficas de MFCC para pacientes con AFIB muestran una irregularidad en la distribución de las magnitudes de los coeficientes, con picos y valles que no siguen un patrón decreciente uniforme. Las magnitudes más altas se concentran en los coeficientes de orden bajo (especialmente el segundo), lo que podría indicar una fuerte presencia de componentes de baja frecuencia en las señales cardíacas. El signo de los coeficientes varía, con la mayoría siendo positivos, pero con la aparición de valores negativos en coeficientes de orden medio-alto, lo que refleja características espectrales específicas (valles) que son comunes en señales complejas y a menudo irregulares como las de la fibrilación auricular. La alta magnitud del coeficiente 13 en casi todas las gráficas sugiere una característica distintiva en la parte superior del espectro de Mel que podría ser relevante para la detección de AFIB.

Las gráficas muestran que, en general, los coeficientes MFCC de orden bajo (como el segundo y el tercero) tienden a tener las magnitudes más altas, con un descenso gradual a medida que el orden del coeficiente aumenta. El primer coeficiente (índice 1) a menudo tiene una magnitud cercana a cero o ligeramente positiva, lo cual es esperable ya que a menudo se normaliza o representa la energía total de la señal. Los coeficientes de orden más alto (a partir del octavo o noveno en adelante) suelen presentar magnitudes más bajas, y en ocasiones, valores negativos, indicando características espectrales menos prominentes o fluctuaciones sutiles.

MUSE_20180116_124254_79000 - SB

El segundo coeficiente tiene la magnitud más alta, alcanzando aproximadamente 32.5. Los coeficientes subsiguientes muestran una disminución progresiva en magnitud, con una tendencia más suave que en las señales de AFIB. Se observa un pico notable en el octavo coeficiente (alrededor de 20) y en el décimo (alrededor de 15). El último coeficiente (13) presenta una magnitud excepcionalmente alta (casi 40). El primer coeficiente es

ligeramente negativo (alrededor de -2.5). Todos los demás coeficientes hasta el 12 son positivos, lo que sugiere una estructura espectral con menos valles profundos en las bandas de frecuencia Mel para estos órdenes. Esta señal muestra una progresión de magnitudes relativamente más regular que las de AFIB, aunque con picos en los coeficientes 8 y 10. La ausencia de valores negativos en los coeficientes intermedios (2-12) y la tendencia más definida de disminución de la magnitud podría reflejar un ritmo cardíaco más regular y predecible, característico de la bradicardia sinusal, en comparación con la irregularidad de la fibrilación auricular.




Figura 17 gráfica de los 13 índices utilizando MFCC

MUSE_20180114_073429_68000 - SB

Al igual que en el caso anterior, el segundo coeficiente es el de mayor magnitud (aproximadamente 32.5). Se observa una disminución gradual en las magnitudes de los coeficientes de orden superior, con un leve repunte en el quinto (alrededor de 5) y el décimo (alrededor de 7.5). El coeficiente 13 es nuevamente muy elevado. El primer coeficiente es negativo (alrededor de -2.5). Todos los demás coeficientes hasta el 12 son positivos. La secuencia de coeficientes presenta una tendencia más suave y una menor fluctuación en comparación con las señales de AFIB. A pesar de los pequeños repuntes, la progresión general es de una disminución relativamente más ordenada, lo cual es coherente con la naturaleza más regular de la bradicardia sinusal, donde el ritmo cardíaco es lento pero consistentemente rítmico.




Figura 18 gráfica de los 13 índices utilizando MFCC

MUSE_20180112_170236_58000 - SB

El segundo coeficiente es el más prominente, con una magnitud cercana a 32.5. Las magnitudes de los coeficientes

siguientes tienden a disminuir, con pequeños repuntes en los coeficientes 5 (alrededor de 7.5) y 8 (alrededor de 10), y un claro pico en el décimo (alrededor de 10). El coeficiente 13 es muy alto. El primer coeficiente es negativo (alrededor de -2.5). Se observa un coeficiente negativo en el sexto (alrededor de -1.0) y en el undécimo (alrededor de -1.0).

Regularidad/Irregularidad: Esta señal exhibe una tendencia general de disminución de la magnitud de los coeficientes, aunque con algunas variaciones. La presencia de valores negativos en los coeficientes 6 y 11, aunque no tan pronunciados como algunos valores negativos en las señales de AFIB, indica ciertas características espectrales en esas bandas de frecuencia. Sin embargo, la estructura general sigue siendo más coherente y menos caótica que la observada en la fibrilación auricular.

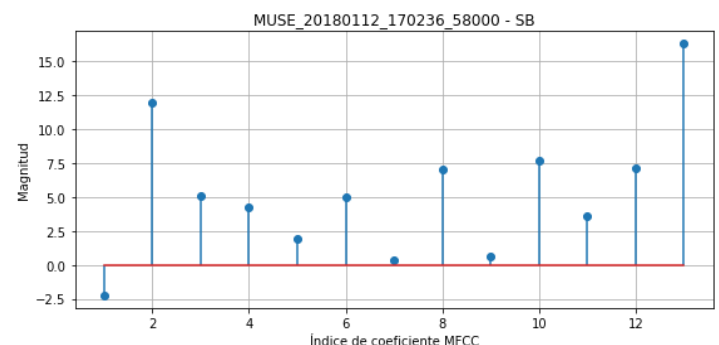


Figura 19 gráfica de los 13 índices utilizando MFCC

Las gráficas de MFCC para la bradicardia sinusal (SB) tienden a mostrar una mayor regularidad en la disminución de las magnitudes de los coeficientes, en comparación con la fibrilación auricular. Si bien el segundo coeficiente conserva la magnitud más alta, la dispersión de las magnitudes a lo largo de los demás coeficientes es más predecible. La presencia de valores negativos en los coeficientes de orden bajo o medio es común en el primer coeficiente, y en algunos casos específicos en otros coeficientes, indicando valles en el espectro. No obstante, la variabilidad en los signos y magnitudes es menos errática que en AFIB, reflejando un ritmo cardíaco más estable, aunque lento. El coeficiente 13, consistentemente alto, sugiere una característica de alta frecuencia común en estas señales.

Capacidad discriminatoria

Para evaluar la capacidad discriminativa de los métodos de extracción de características sobre señales ECG, se realizó una normalización de las características F1 a F13 por separado para cada método (MFCC, DFT y DCT). Esto permitió comparar directamente las distribuciones de las características entre las clases de arritmia AFIB y SB, eliminando posibles efectos de escala entre métodos.

Las Figuras 14 a 16 presentan diagramas de caja (boxplots) para cada característica, segmentados por tipo de arritmia y

coloreados según el método empleado. Se observan las siguientes tendencias generales:

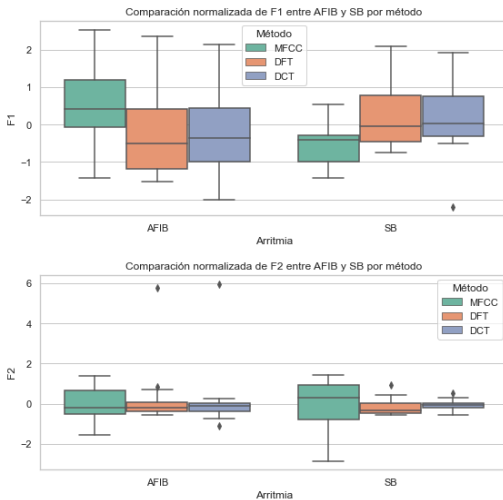


Figura 20 diagramas de caja (boxplots) para cada característica, segmentados por tipo de arritmia y método

Características F1 y F2: La característica F1 muestra diferencias notorias entre AFIB y SB, particularmente para el método MFCC, donde los valores para AFIB tienden a ser más altos. En F2, sin embargo, las diferencias son menos marcadas entre clases y métodos, con distribuciones centradas cerca de cero, aunque se observan algunos valores atípicos.

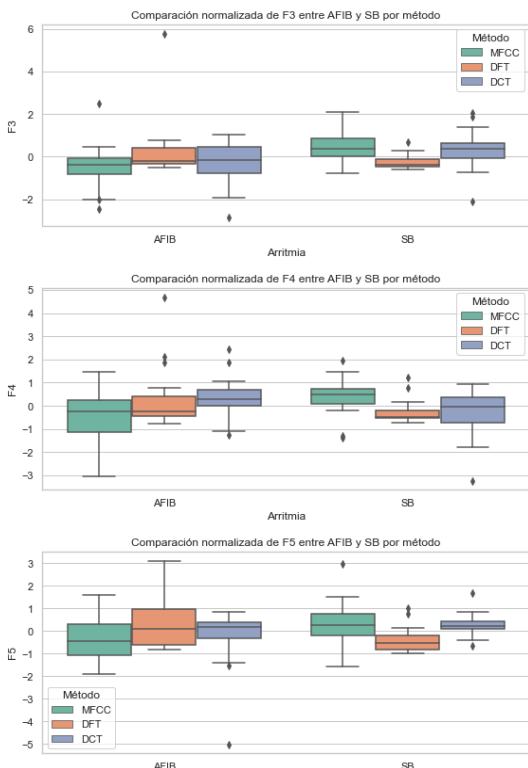


Figura 21 diagramas de caja (boxplots) para cada característica, segmentados por tipo de arritmia y método

Características F3 a F5: Estas características presentan una dispersión moderada y, en algunos casos, diferencias claras entre clases dependiendo del método. Por ejemplo, F4 muestra una mayor separación de medianas en MFCC entre AFIB y SB, mientras que DFT y DCT muestran comportamientos más similares entre clases.

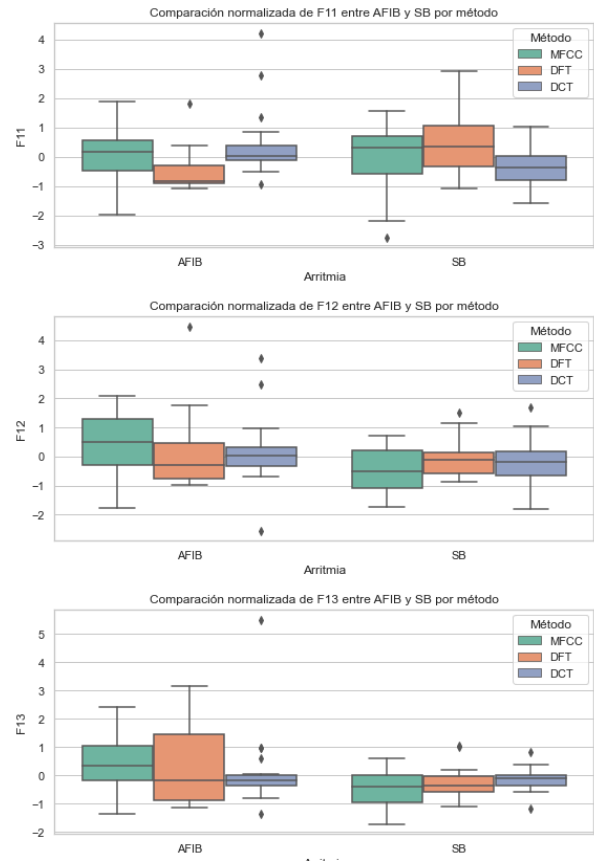


Figura 22 diagramas de caja (boxplots) para cada característica, segmentados por tipo de arritmia y método

Características F11 a F13: Las características F11 y F12 con MFCC muestran una mayor dispersión en los valores para la clase AFIB respecto a SB, lo cual podría estar relacionado con la mayor complejidad espectral de estos registros. En F13, nuevamente se observa que MFCC y DFT presentan diferencias entre clases más pronunciadas que DCT.

Con el objetivo de evaluar si existen diferencias estadísticamente significativas en las características extraídas (F1 a F13) entre los grupos de arritmia **AFIB** y **SB**, se planteó la siguiente hipótesis estadística para cada característica y método de extracción:

- **Hipótesis nula (H_0):** No hay diferencia significativa en la distribución de la característica F_i entre los grupos AFIB y SB.

- **Hipótesis alternativa (H_1):** Existe una diferencia significativa en la distribución de la característica F_i entre los grupos AFIB y SB.

Dado que las distribuciones no presentan normalidad y las escalas originales varían entre métodos, se aplicó la prueba no paramétrica de Mann–Whitney U para contrastar si existen diferencias estadísticamente significativas entre los grupos de arritmia (AFIB vs SB) en cada característica y método.

Se consideró un umbral de significancia $\alpha=0.05$. Los resultados se resumen a continuación:

MFCC: De las 13 características analizadas, 8 mostraron diferencias significativas ($p < 0.05$), lo que indica una fuerte capacidad discriminativa del método MFCC.

DFT: En contraste, solo 4 características mostraron diferencias significativas con DFT. La mayoría de las características no presentó evidencia estadística suficiente para rechazar la hipótesis nula.

DCT: Para DCT, 2 características (F_3 , F_{10} y F_{11}) presentaron diferencias significativas. Aunque muestra algo de capacidad discriminativa, su desempeño general es inferior al de MFCC.

Los resultados los podemos observar en la siguiente tabla:

```
=== Pruebas Mann-Whitney entre AFIB y SB ===

--- Método: MFCC ---
F1: p = 0.0004 SI
F2: p = 0.6750 NO
F3: p = 0.0011 SI
F4: p = 0.0133 SI
F5: p = 0.0207 SI
F6: p = 0.7557 NO
F7: p = 0.0011 SI
F8: p = 0.0720 NO
F9: p = 0.0601 NO
F10: p = 0.0155 SI
F11: p = 0.9246 NO
F12: p = 0.0047 SI
F13: p = 0.0084 SI

--- Método: DFT ---
F1: p = 0.0962 NO
F2: p = 0.1719 NO
F3: p = 0.0565 NO
F4: p = 0.0764 NO
F5: p = 0.0294 SI
F6: p = 0.7972 NO
F7: p = 0.9676 NO
F8: p = 0.9676 NO
F9: p = 0.0499 SI
F10: p = 0.0005 SI
F11: p = 0.0006 SI
F12: p = 0.7353 NO
F13: p = 0.3648 NO

--- Método: DCT ---
F1: p = 0.1478 NO
F2: p = 0.3369 NO
F3: p = 0.0499 SI
F4: p = 0.0810 NO
F5: p = 0.4094 NO
F6: p = 0.5428 NO
F7: p = 0.1404 NO
F8: p = 0.8181 NO
F9: p = 0.2287 NO
F10: p = 0.9461 NO
F11: p = 0.0047 SI
F12: p = 0.2503 NO
F13: p = 0.9892 NO
```

Figura 23 p-values de cada una de las 13 características por cada método

Para facilitar la interpretación de los resultados obtenidos mediante la prueba de Mann–Whitney U, se construyó un mapa de calor que visualiza los valores p de cada característica (F_1 a F_{13}) comparando los grupos AFIB y SB bajo los tres métodos de extracción: MFCC, DFT y DCT (ver Figura 5).

En el heatmap se utilizó una paleta de color centrada en un valor crítico de referencia ($\alpha=0.05$), lo cual permite distinguir rápidamente qué características resultaron estadísticamente significativas (valores en tonos azulados claros o fríos) y cuáles no (tonos rojizos más cálidos). Esta representación ofrece una vista global y comparativa entre métodos, mejorando la comprensión de patrones de significancia entre características y estrategias de extracción.




Figura 24 Mapa de calor de la relación de los 13 p-values obtenidos con Mann-Whitney para las 2 arritmias contra los 3 métodos utilizados

I. ANÁLISIS

El análisis espectral de señales ECG a través de la Transformada Discreta de Fourier (FFT) ha demostrado ser una herramienta eficaz para capturar diferencias significativas en la distribución de energía entre distintos tipos de ritmos cardíacos. En este estudio, se identificaron patrones espectrales característicos que distinguen la fibrilación auricular (AFIB) de la bradicardia sinusal (SB), lo cual concuerda con hallazgos previos en la literatura que destacan la utilidad de la FFT para el análisis de señales fisiológicas no estacionarias [3].

- Frecuencia dominante

Las señales AFIB presentaron frecuencias dominantes variables (6.50, 3.30 y 1.90 Hz) frente a las SB que demostraron relativa estabilidad (3.80, 3.90 y 3.00 Hz). Aunque en términos absolutos estas diferencias parecen pequeñas, tienen relevancia clínica, reflejando frecuencias cardíacas promedio variantes en AFIB, pero con un ritmo promedio superior a los 60 latidos por minuto, indicando un ritmo acelerado o presencia de múltiples armónicos, frente a la bradicardia de menos de 60 latidos por minuto [5], la señal MUSE_20180116_173659_51000 (SB) evidenció una frecuencia dominante más baja (3.00 Hz), congruente con una frecuencia cardíaca reducida.

Estos resultados están en línea con lo descrito por Malik et al. (1996) [6], quienes relacionan la frecuencia cardíaca con los componentes dominantes del espectro, y por Clifford et al. (2006) [7], que resaltan la utilidad del análisis espectral para caracterizar dinámicas cardíacas.

- **Energía total del espectro**

Se observó que las señales AFIB presentaron una mayor energía espectral total, en particular MUSE_20180209_170623_53000 y MUSE_20180210_124246_00000 con valores de 2.59×10^{10} y 4.69×10^{10} , respectivamente. En contraste, las señales SB presentaron energías inferiores, destacando MUSE_20180116_173659_51000 con 1.32×10^9 . Esta disparidad puede atribuirse a la mayor amplitud y complejidad morfológica de los complejos QRS y demás ondas en señales AFIB, que genera un contenido energético altamente superior en el espectro [8]. Además, la energía total refleja indirectamente la relación señal-ruido, sugiriendo que las señales AFIB pueden tener mayor variabilidad fisiológica.

- **Banda útil**

La banda útil, definida como el rango de frecuencias con potencia superior al 5% del máximo, mostró también diferencias claras: las señales SB tendieron a concentrar su energía en bandas estrechas, como en MUSE_20180116_124254_79000 (0.8 0–8.60 Hz), mientras que las señales AFIB extendieron su espectro a frecuencias más altas, por ejemplo MUSE_20180113_135820_25000 hasta 32.41 Hz. Esta expansión espectral en AFIB indica una mayor complejidad eléctrica, posiblemente asociada a la actividad de las ondas P y T, así como a la dinámica autonómica, relacionándose directamente con la cantidad de latidos por minuto que se presentaron en la mayoría de casos para esta arritmia [9].

Este hallazgo concuerda con los estudios de Addison (2005) [10], que reportan la presencia de componentes de alta frecuencia vinculados a variabilidad respiratoria y otros procesos neurovegetativos en el ECG.

- **Interpretación fisiológica**

Las diferencias espectrales entre SB y AFIB reflejan las características fisiológicas subyacentes. En SB, la disminución en la frecuencia de descarga del nodo sinoauricular produce una señal con periodicidad prolongada y menor contenido de alta frecuencia, reflejando un sistema nervioso parasimpático predominante y un patrón rítmico estable [11]. En contraste, AFIB exhibe mayor frecuencia y complejidad, derivadas de una regulación autonómica más dinámica y de la interacción

entre distintos mecanismos electrofisiológicos que modulan la forma y duración del complejo QRS y las ondas adyacentes [12].

La mayor dispersión espectral y energía en AFIB puede además implicar una mayor capacidad adaptativa del sistema cardiovascular ante estímulos internos y externos, mientras que la restricción espectral en SB puede ser indicativa de un estado más estático o fisiológicamente deprimido, tal como se espera de estas enfermedades.

- **Magnitud de los Coeficientes DCT**

AFIB: Los estudios han demostrado que las señales de fibrilación auricular presentan coeficientes DCT de alta magnitud dispersos a lo largo del espectro. Esta dispersión refleja la naturaleza caótica y la alta variabilidad de la actividad eléctrica en AFIB. Por ejemplo, en el trabajo de *Lahmiri y Bekiros (2025)[34]*, se utilizó la DCT para extraer características de alta amplitud que permitieron distinguir eficazmente entre ritmos normales y arrítmicos, destacando la presencia de coeficientes significativos en frecuencias intermedias y altas .

SB: En contraste, las señales de bradicardia sinusal muestran una concentración de energía en los primeros coeficientes DCT, con una rápida disminución en las magnitudes subsiguientes. Esta característica indica una señal más regular y de baja frecuencia, coherente con el ritmo lento y ordenado de la bradicardia sinusal. La misma investigación de *Lahmiri y Bekiros (2025)[34]* respalda esta observación, al señalar que los coeficientes de alta amplitud en ritmos normales se concentran en las bajas frecuencias .

- **Signo de los Coeficientes DCT**

AFIB: La alternancia frecuente de signos en los coeficientes DCT de las señales de AFIB indica una variabilidad significativa en la morfología de la señal. Esta característica es consistente con la irregularidad del ritmo cardíaco en la fibrilación auricular. [35]

SB: Las señales de bradicardia sinusal tienden a mostrar una mayor uniformidad en el signo de los coeficientes DCT, reflejando la estabilidad y regularidad del ritmo sinusal. [35]

- **Regularidad en el Espectro DCT**

AFIB: La distribución irregular y dispersa de los coeficientes DCT en las señales de AFIB es indicativa de una actividad eléctrica desorganizada. Esta irregularidad espectral ha sido utilizada como un marcador para la detección de fibrilación auricular en varios estudios.[34]

SB: Por otro lado, la regularidad en la distribución de los coeficientes DCT en las señales de bradicardia sinusal

refleja un ritmo cardíaco estable y predecible. Esta característica ha sido aprovechada en sistemas de diagnóstico asistido por computadora para distinguir entre ritmos normales y patológicos. [34]

El análisis de los coeficientes DCT proporciona información valiosa sobre la naturaleza de las señales de ECG. Las diferencias en la magnitud, el signo y la regularidad de estos coeficientes entre las señales de AFIB y SB son consistentes con los hallazgos reportados en la literatura científica. Estas características pueden ser utilizadas eficazmente en sistemas de diagnóstico automatizado para mejorar la detección y clasificación de arritmias cardíacas.

- Magnitud de los Coeficientes MFCC

La magnitud de los coeficientes MFCC refleja la distribución de energía en diferentes bandas de frecuencia en la escala Mel.

En arritmias como la Fibrilación Auricular (AFIB): se mostraron magnitudes elevadas en los coeficientes de orden bajo (especialmente el segundo), con fluctuaciones significativas en los coeficientes de orden medio. La literatura concuerda en que la AFIB, al ser una arritmia caótica con actividad eléctrica auricular desorganizada, se caracteriza por una compleja morfología de la señal. Esto puede traducirse en una distribución de energía menos predecible a través del espectro, resultando en patrones MFCC con picos y valles irregulares, especialmente en los coeficientes de orden bajo y medio que capturan la información más prominente del espectro. [36]

En la Bradicardia Sinusal (SB): En contraste, las gráficas de SB mostraron una tendencia más regular y suave en la disminución de las magnitudes, aunque el segundo coeficiente también presentaba la magnitud más alta. Esto es consistente con la bradicardia sinusal, que es un ritmo cardíaco lento pero generalmente regular. Las señales de SB, al tener una estructura rítmica más consistente, tienden a exhibir una distribución de energía espectral más predecible, lo que se refleja en una progresión más ordenada de las magnitudes de los MFCC. [37]

- Signo de los Coeficientes MFCC

Los MFCC se derivan de la Transformada de Coseno Discreta (DCT) del logaritmo de las energías del filtro Mel, y la DCT puede producir valores tanto positivos como negativos. En AFIB: se ve la presencia de coeficientes negativos en diferentes órdenes (e.g., sexto y undécimo). Estos valores negativos pueden indicar valles o caídas en el espectro de potencia en las bandas de frecuencia correspondientes, lo cual es esperable en señales con una morfología compleja y caótica como la AFIB, donde hay una amplia gama de componentes de frecuencia y una falta

de un patrón dominante. [38,36]

En SB: En nuestras observaciones, el primer coeficiente de SB a menudo era negativo o cercano a cero, y la aparición de otros coeficientes negativos fue menos frecuente o de menor magnitud en comparación con la AFIB. Esta relativa ausencia de valles profundos en el espectro (reflejada en la predominancia de coeficientes positivos, excepto el primero en algunos casos) puede ser un indicativo de una señal más "limpia" y rítmica, sin las perturbaciones espectrales asociadas a la desorganización de la fibrilación. [37]

- Regularidad/Irregularidad en el Espectro

En AFIB: se resaltó la irregularidad en la secuencia de coeficientes MFCC para AFIB, con picos y valles que no seguían un patrón decreciente uniforme. La literatura sugiere que la variabilidad de la frecuencia cardíaca y la ausencia de una onda P discernible en el ECG de AFIB se traducen en una huella espectral altamente irregular y compleja. Los MFCC, al capturar esta complejidad, mostrarán una mayor dispersión y fluctuaciones en sus valores, lo que los hace efectivos para distinguir AFIB de ritmos más regulares [38].

En SB: Por el contrario, las gráficas de SB mostraron una mayor regularidad en la progresión de los coeficientes. Aunque hubo algunas variaciones, la tendencia general de disminución de la magnitud fue más consistente. Esto refleja la naturaleza de la bradicardia sinusal, que, si bien es un ritmo lento, mantiene una regularidad en los intervalos de tiempo entre latidos. Un espectro más ordenado y predecible resultará en una progresión más suave y menos caótica de los coeficientes MFCC [36].

La magnitud, el signo y la regularidad de los coeficientes MFCC son características distintivas para diferenciar entre arritmias como la AFIB y la SB. Las señales de AFIB tienden a presentar una mayor irregularidad en la distribución de las magnitudes y signos de los MFCC, reflejando la complejidad y el caos intrínseco de esta arritmia. En contraste, las señales de SB muestran una mayor regularidad en los patrones de los MFCC, lo que indica un ritmo cardíaco más estable, aunque lento. Estos hallazgos son consistentes con la literatura científica, que utiliza los MFCC como potentes descriptores de las características espectrales de las señales biomédicas para la clasificación automática de arritmias cardíacas [36, 37,38].

Comparativa DFT-DCT-MFCC

Los resultados obtenidos a partir de la prueba de Mann-Whitney U permiten evidenciar diferencias importantes en la capacidad discriminativa de las características extraídas mediante los tres métodos espectrales analizados: MFCC, DFT y DCT. En primer lugar, el método MFCC mostró un desempeño superior en la

identificación de diferencias estadísticas significativas entre los grupos analizados, con un total de 8 de 13 características relevantes que evidenciaron valores p inferiores a 0.05. Este hallazgo indica que los coeficientes frecuenciales capturan eficazmente las variaciones espectrales asociadas a diferentes tipos de arritmias, validando así su utilidad en el análisis y clasificación de señales ECG. Este resultado es consistente con la literatura, donde MFCC ha demostrado ser especialmente sensible a cambios sutiles en el espectro de señales biomédicas y en aplicaciones de reconocimiento de patrones [20][21].

En contraste, el método DCT presentó un número considerablemente menor de características con poder discriminativo estadísticamente significativo, limitándose a solo dos. Esta reducción en la capacidad discriminativa puede atribuirse a la naturaleza del DFT, que, si bien es una herramienta clásica para el análisis espectral, puede verse afectada por su limitada resolución temporal y su sensibilidad a ruidos o artefactos presentes en señales no estacionarias como el ECG. Esto limita su eficacia para distinguir patrones espectrales específicos de arritmias complejas [22].

Por último, el método DFT mostró un desempeño intermedio, con cuatro características significativas. La DFT, que permite representar la señal de forma compacta y eficiente en términos de energía, ofrece cierta capacidad para discriminar patrones espectrales relevantes, aunque no alcanza la robustez observada en MFCC. Esta diferencia puede estar relacionada con la forma en que DFT maneja la energía espectral y la compacidad de la señal, lo que podría limitar su sensibilidad a cambios finos en las características espectrales propias de las arritmias.

Para evaluar la diferencia en la distribución de las características extraídas entre los grupos AFIB y SB, se aplicó la prueba no paramétrica de Mann–Whitney U, adecuada en este caso debido a que los datos no presentan una distribución normal y las escalas de las características varían entre métodos. Esta prueba permite comparar dos grupos independientes sin asumir normalidad. Los resultados de esta prueba se representan visualmente mediante un mapa de calor de p -valores, donde se muestran las trece características analizadas (F1 a F13) a través de tres métodos de extracción: MFCC, DFT y DCT.

El análisis visual del mapa de calor evidencia que el método MFCC es el que logra detectar un mayor número de diferencias estadísticamente significativas entre AFIB y SB. En particular, las características F1, F3, F4, F5, F7, F10, F12 y F13 presentaron valores de p menores a 0.05, indicando que estos descriptores permiten distinguir de manera significativa entre ambos grupos. Esto sugiere que MFCC, que basa su extracción en escalas logarítmicas perceptuales del espectro de la señal, es especialmente

eficaz para captar alteraciones características de la fibrilación auricular, como la variabilidad en la energía espectral y la dispersión frecuencial, tal como ha sido reportado en estudios previos sobre análisis de ritmos cardíacos.

En contraste, los métodos DFT y DCT presentaron menor capacidad discriminativa. DFT mostró significancia únicamente en las características F5, F10 y F11, mientras que DCT solo arrojó diferencias significativas en F3, F10 y F11. Esto podría deberse a que ambos métodos están limitados a representaciones más generales de la frecuencia y no integran la sensibilidad espectral no lineal que proporciona MFCC. A pesar de ello, cabe destacar que las características F10 y F11 emergen como estadísticamente significativas en los tres métodos, lo cual sugiere que estas métricas podrían representar descriptores robustos e invariantes al método de extracción, y por tanto, útiles como biomarcadores para la clasificación entre ritmos normales y patológicos.

Se puede entonces concluir que el análisis estadístico y visual confirma que el método MFCC es el más sensible para detectar diferencias entre señales AFIB y SB, mientras que DFT y DCT, aunque útiles, presentan una menor cantidad de características significativas. Estas observaciones son coherentes con literatura especializada que posiciona a MFCC como un método altamente informativo para el análisis de señales biomédicas complejas. El uso del mapa de calor ha sido clave para identificar de forma clara las combinaciones de método y características que aportan mayor valor discriminativo en el contexto del análisis de señales de ritmo cardíaco.

IV. CONCLUSIONES

El presente estudio permitió demostrar que el análisis espectral aplicado a señales electrocardiográficas es una herramienta efectiva para discriminar entre ritmos cardíacos normales y patológicos, particularmente entre sinusal basal (SB) y fibrilación auricular (AFIB). A través de la implementación de tres técnicas de extracción de características (Transformada Discreta de Fourier (DFT), Transformada Discreta del Coseno (DCT) y Coeficientes Cepstrales en Frecuencias de Mel (MFCC)) se evaluó la capacidad de cada método para representar y distinguir patrones morfológicos y dinámicos característicos del ECG.

Los resultados obtenidos a partir de la prueba estadística de Mann–Whitney U indicaron que el método MFCC ofreció la mayor sensibilidad para diferenciar entre clases, con la mayoría de sus características mostrando significancia estadística ($p < 0.05$). Esto sugiere que los MFCC son especialmente útiles para capturar las variaciones espectrales sutiles presentes en registros AFIB. En

comparación, DFT y DCT mostraron una menor cantidad de características discriminantes, lo que evidencia que, aunque útiles, podrían ser más limitados para representar alteraciones no lineales o de alta variabilidad como las presentes en la fibrilación auricular.

Asimismo, la inclusión de métricas adicionales como parámetros de variabilidad de la frecuencia cardíaca (HRV) y medidas no lineales (SDNN, RMSSD, ApEn) reforzó la caracterización de los grupos, destacando que la fibrilación auricular se asocia con una mayor irregularidad rítmica y complejidad temporal.

En conjunto, los hallazgos de este proyecto respaldan el uso de análisis espectral, y en particular de los MFCC, como base para el desarrollo de sistemas automáticos de clasificación de arritmias. Además, se destaca la importancia de integrar múltiples tipos de características (frecuenciales, no lineales y estadísticas) para mejorar la precisión y robustez de las herramientas diagnósticas en el ámbito clínico. Este enfoque multidimensional representa un aporte valioso para la ingeniería biomédica orientada al monitoreo y análisis inteligente de señales fisiológicas.

REFERENCIAS

- [1] F. Umetani, D. H. Singer, R. McCraty, and M. Atkinson, "Twenty-four hour time domain heart rate variability and heart rate: relations to age and gender over nine decades," *J. Am. Coll. Cardiol.*, vol. 31, no. 3, pp. 593–601, 1998.
- [2] A. Voss, R. Schroeder, A. Heitmann, A. Peters, and S. Perz, "Short-term heart rate variability—influence of gender and age in healthy subjects," *PLoS ONE*, vol. 7, no. 3, p. e37753, 2012.
- [3] H. Zulkifly, G. Y. H. Lip, and D. A. Lane, "Epidemiology of atrial fibrillation," *Int. J. Clin. Pract.*, vol. 72, no. 3, p. e13070, 2018. doi: 10.1111/ijcp.13070.
- [4] J. Zheng et al., "A 12-lead electrocardiogram database for arrhythmia research covering more than 10,000 patients," *Sci. Data*, vol. 7, no. 1, p. 48, 2020. doi: 10.1038/s41597-020-0380-2.
- [5] P. Kirchhof et al., "2016 ESC Guidelines for the management of atrial fibrillation developed in collaboration with EACTS," *Eur. Heart J.*, vol. 37, no. 38, pp. 2893–2962, 2016. doi: 10.1093/eurheartj/ehw210.
- [6] J. Shaffer and J. P. Ginsberg, "An Overview of Heart Rate Variability Metrics and Norms," *Front. Public Health*, vol. 5, p. 258, 2017. doi: 10.3389/fpubh.2017.00258.
- [7] M. Brennan, M. Palaniswami, and P. Kamen, "Do existing measures of Poincaré plot geometry reflect nonlinear features of heart rate variability?," *IEEE Trans. Biomed. Eng.*, vol. 48, no. 11, pp. 1342–1347, 2001. doi: 10.1109/10.959330.
- [8] A. Voss, J. Schulz, R. Schroeder, M. Baumert, and P. Caminal, "Methods derived from nonlinear dynamics for analysing heart rate variability," *Philos. Trans. R. Soc. A*, vol. 367, no. 1887, pp. 277–296, 2009.
- [9] J. Piskorski and P. Guzik, "Geometry of the Poincaré plot of RR intervals and its asymmetry in healthy adults," *Physiol. Meas.*, vol. 28, no. 3, pp. 287–300, 2007.
- [10] R. Castiglioni, A. Faini, A. Parati, and G. Rizzo, "Wearable continuous monitoring of heart rate variability: Impact of noise and artifacts," *Physiol. Meas.*, vol. 40, no. 3, p. 035006, 2019.
- [11] R. Castiglioni et al., "A real-time method for measuring heart rate variability during exercise," *Med. Biol. Eng. Comput.*, vol. 55, pp. 1287–1296, 2017. doi: 10.1007/s11517-016-1578-6.
- [12] A. K. Singh and S. Krishnan, "ECG signal feature extraction trends in methods and applications," *BioMed. Eng. Online*, vol. 22, no. 22, 2023. doi: 10.1186/s12938-023-01075-1.
- [13] S. Ahmed et al., "ECG Biometric Recognition Based on Discrete Cosine Transform and Autocorrelation," *IEEE Access*, vol. 7, pp. 126146–126155, 2019.
- [14] L. A. Manilo, A. P. Nemirko, E. G. Evdakova, and A. A. Tatarinova, "ECG Database for Evaluating the Efficiency of Recognizing Dangerous Arrhythmias," in *Proc. 2021 Int. Conf. Comput. Sci. and Eng. (CSGB)*, pp. 120–123, May 2021. doi: 10.1109/CSGB53040.2021.9496029.
- [15] S. Bellock, R. H. Whittington, and G. Garner, "Analysis of ECG data for arrhythmia," U.S. Patent US9993173B2, Sep. 06, 2016. [Online]. Available: <https://patents.google.com/patent/US9993173B2/en>
- [16] P. Carreiras, D. Alves, and F. Silva Cunha, "BioSPPy: Biomedical Signal Processing in Python." [Online]. Available: <https://github.com/PIA-Group/BioSPPy>
- [17] D. Sedghamiz, "py-ecg-detectors: Python implementation of popular ECG R-peak detection algorithms," 2018. [Online]. Available: <https://github.com/berndporr/py-ecg-detectors>
- [18] P. van Gent, "HeartPy: A heart rate analysis toolkit for Python," *J. Open Source Softw.*, vol. 4, no. 39, p. 1440, 2019. doi: 10.21105/joss.01440.

- [19] J. Makowski, M. D. Pham, and M. Martorell-Marugán, "NeuroKit2: A Python toolbox for neurophysiological signal processing," *PeerJ Comput. Sci.*, vol. 7, p. e261, 2021. doi: 10.7717/peerj-cs.261.
- [20] O. S. Acevedo, A. F. Agudelo, M. Santamaría, "Análisis de señales ECG y detección de arritmias (Proyecto 1)," Facultad de Ingeniería, Bioingeniería, Universidad Nacional de Colombia, 2024.
- [21] E. Uslu and G. Bilgin, "Exploiting locality based Fourier transform for ECG signal diagnosis," *International Conference on Applied Electronics*, pp. 323–326, Oct. 2012. [Online]. Available: IEEE Xplore
- [22] Kuo, Y. S., Kim, K., & Whitehouse, K. (2011). Extracting physiological signals using DCT-based signal processing for body sensor networks. *IEEE Transactions on Mobile Computing*, 12(5), 1023–1035.
- [23] Ahmed, N., Natarajan, T., & Rao, K. R. (1974). Discrete cosine transform. *IEEE Transactions on Computers*, 100(1), 90–93.
- [24] Acharya, U. R., Fujita, H., Lih, O. S., et al. (2017). Automated detection of arrhythmias using different intervals of tachycardia ECG segments with convolutional neural network. *Information Sciences*, 405, 81–90.
- [25] Clifford, G. D., Azuaje, F., McSharpy, P. E. (2006). *Advanced methods and tools for ECG data analysis*. Artech House.
- [26] Janse, M. J. (2004). *Electrophysiological Basis for Cardiac Arrhythmias*. Springer.
- [27] Malik, M., et al. (1996). Heart rate variability: Standards of measurement, physiological interpretation and clinical use. *European Heart Journal*, 17(3), 354–381.
- [28] Clifford, G. D., Azuaje, F., & McSharpy, P. E. (2006). *Advanced Methods and Tools for ECG Data Analysis*. Artech House.
- [29] Rangayyan, R. M. (2002). *Biomedical Signal Analysis: A Case-Study Approach*. IEEE Press.
- [30] Berntson, G. G., et al. (1997). Heart rate variability: Origins, methods, and interpretive caveats. *Psychophysiology*, 34(6), 623–648.
- [31] Addison, P. S. (2005). Wavelet transforms and the ECG: a review. *Physiological Measurement*, 26(5), R155–R199.
- [32] Malik, M., et al. (1998). Heart rate variability: Clinical applications and interpretation. *Annals of Noninvasive Electrocardiology*, 3(2), 88–101.
- [33] Huikuri, H. V., & Stein, P. K. (2013). Heart rate variability in risk stratification of cardiac patients. *Progress in Cardiovascular Diseases*, 56(2), 153–159.
- [34] Lahmiri, S., & Bekiros, S. (2025). An Effective and Fast Model for Characterization of Cardiac Arrhythmia and Congestive Heart Failure. *Diagnostics*, 15(7), 849. <https://doi.org/10.3390/diagnostics15070849>
- [35] Abdelazez, M., Rajan, S., & Chan, A. D. C. (2022). Detection of Atrial Fibrillation in Compressively Sensed Electrocardiogram for Remote Monitoring. *Frontiers In Electronics*, 3. <https://doi.org/10.3389/felec.2022.906689>
- [36] Automatic Detection of Short-Term Atrial Fibrillation Segments Based on Frequency Slice Wavelet Transform and Machine Learning Techniques - MDPI. <https://www.mdpi.com/1424-8220/21/16/5302>
- [37] Biometric Individual Identification System Based on the ECG Signal - ResearchGate. https://www.researchgate.net/publication/356594899_Biometric_Individual_Identification_System_Based_on_the_ECG_Signal
- [38] Optimized deep residual networks for early detection of myocardial infarction from ECG signals - PMC. <https://pmc.ncbi.nlm.nih.gov/articles/PMC12085857/>